Projet final – Science des données (module S7MOI1)

Qui appeler en priorité avant un défaut de carte de crédit ?

Mieux cibler les appels préventifs d'une banque avec un modèle de risque

Rapport de synthèse

Réalisé par : CHEIKH MOHAMED VADEL MAMINA

2AE – ECAM-EPMI

Encadrant : Yann Skonieczny

Octobre 2026

Sommaire

Résumé *3*

1. Cadrage métier *3*

2. Type de problème *4*

3. Analyse des données *4*

3.1 Source et qualité 4

3.2 Constats clés 5

3.3 Audit de fuite et variables construites 5

4. Développement du modèle *5*

4.1 Découpage, pipeline et validation 5

4.2 Diagnostic 6

5. Choix des métriques *7*

6. Justification par les coûts *7*

6.1 Des probabilités fiables 7

6.2 Hypothèses de coût 8

6.3 Matrice de coûts et seuil de rentabilité 8

6.4 Comparaison des politiques sur le test 8

7. ROI potentiel *9*

8. Présentation des résultats *10*

9. Risques et enjeux *10*

9.1 Équité 10

9.2 Registre des risques 11

Conclusion et recommandation *12*

Annexe A – Sources des hypothèses *13*

Annexe B – Données et reproductibilité *13*

Résumé

Chaque mois la banque effectue quelques appels à ses clients afin d'éviter les défauts de paiement de leurs cartes de crédit. Actuellement ils appellent les clients qui ont été en retard dans le paiement de leur facture, ce qui représente environ 23% de leur clientèle (22,1 % sur le jeu de test). Mon modèle calcule la probabilité de faire défaut sur le prochain paiement pour chaque client. Le produit de cette probabilité avec le montant de la facture nous donne **la perte attendue**. Et puis je commence à appeler **ceux qui ont la perte attendue la plus élevée**.

Tableau 1 – Résultats clés sur le jeu de test

Indicateur	Règle actuelle	Modèle retenu
Clients appelés	22,1 %	22,1 %
Montants en défaut couverts	55,3 %	**80,3 %**
ROC-AUC	0,678	**0,778**
Gain annuel estimé	–	**Environ 252 000 €** (197 000 à 309 000 €)
ROI la 1re année (coût du projet : 55 000 €)	–	**358 %**, retour en 2,6 mois

Recommandation : Commencez un **essai de 3 mois** avec une fraction des clients, avec un groupe témoin non appelé, tiré au hasard. Le profit dépendra de l'efficacité des appels ; le projet est rentable dès que les appels empêchent **2,2% des pertes** mais ce chiffre doit être d'abord déterminé par la banque.

1. Cadrage métier

Avant de choisir le modèle j'ai d'abord fixé la décision à améliorer et les critères de mesure du succès.

Tableau 2 – Cadrage du projet

Élément	Contenu
Contexte	Une banque qui émet des cartes de crédit (données d'une banque de Taïwan, 30 000 clients, avril à septembre 2005). Le résultat sert au service recouvrement.
Problème	Environ 22 % des clients ne paient pas leur facture le mois suivant.
Décision	Chaque mois, choisir quels clients appeler avant l'échéance : rappel, proposition d'échéancier.
Horizon	1 mois : j'utilise ce qui est connu fin septembre pour prédire le défaut du mois suivant.
Situation actuelle	Hypothèse : la banque appelle les clients déjà en retard sur le dernier relevé. Sur le test, cette règle appelle 22,1 % des clients et couvre 55,3 % des montants en défaut.
Critère de succès	**Avec le même nombre d'appels, couvrir au moins 70 % des montants en défaut**, vérifié sur le jeu de test, puis à la fin d'un pilote de 3 mois.
Contraintes	N'utiliser que des données connues au moment de la décision ; pouvoir expliquer chaque appel au conseiller ; ne pas utiliser le sexe, l'âge et la situation familiale.

Ma démarche est basée sur les montants et pas simplement sur le nombre de clients : la perte de la banque sera déterminée par la facture et un défaut de paiement d'une grosse facture coûtera beaucoup plus qu'un défaut de paiement d'une petite facture.

2. Type de problème

- La cible (défaut) est 1 si le client fait défaut le mois suivant et 0 s'il ne le fait pas. Cette cible est connue pour tous les clients : c'est une **tâche supervisée** et comme il n'y a que deux valeurs c'est une **classification binaire**. La probabilité de faire défaut générée par le modèle est utilisée avec le montant de la facture pour prendre une décision sur qui appeler. Les raisons de ne pas choisir d'autres alternatives sont :
- **Régression** : La valeur réelle de la perte ne peut pas être trouvée mais nous savons que le client fait défaut.
- **Clustering** : Cette méthode n'utiliserait pas la cible alors qu'elle est connue.
- **Série temporelle** : Tous les clients sont observés à une seule date et l'historique de 6 mois n'est qu'une variable.

3. Analyse des données

3.1 Source et qualité

- **Données** : Défaut de paiement de clients de cartes de crédit (UCI, Yeh, 2009, licence CC BY 4.0). Nombre d'observations = 30 000 clients. Variables : limite, profil (sexe, niveau d'éducation, situation matrimoniale, âge) ; pour chaque mois (d'avril à septembre 2005) retard de paiement, montant facturé, montant payé.
- **Aucune valeur manquante**, aucun identifiant dupliqué. 35 observations sont toutes identiques sauf leur identifiant (clients différents) : ils n'ont presque tous aucune facture, on les garde donc.
- **Codes non documentés** : niveau d'éducation 0,5,6 (345 clients) dans la catégorie "autre" ; situation matrimoniale 0 (54 clients) dans la catégorie "autre". Les codes de retard -2 et 0 signifient "pas de retard" on les garde donc.
- **Anomalie** : le code "un mois de retard" est utilisé pour 3688 clients presque uniquement en septembre. On ne peut pas le corriger on le garde donc comme une limite.
- **Factures et montants** : 1930 ont au moins une facture négative (montant à risque=0 quand c'est celle de septembre), 866 clients n'ont aucune facture du tout, 2115 ont dépassé leur limite. Factures et montants asymétriques : on garde les vrais clients, on applique un logarithme à la régression logistique.

3.2 Constats clés

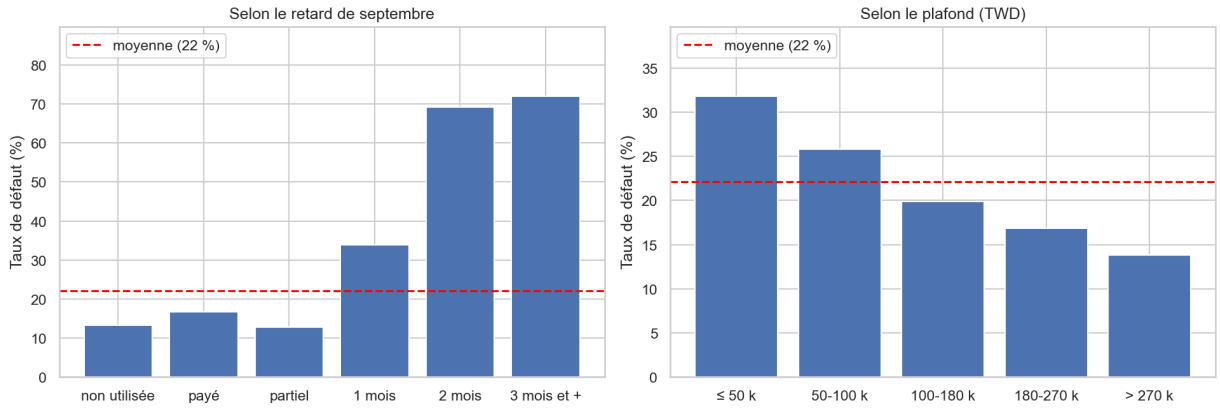


Figure 1 – Taux de défaut selon le retard de septembre et selon le plafond (ligne rouge : moyenne de 22 %) (notebook 01)

- **Le retard de septembre est le signal le plus fort** : 13 à 17 % de défauts sans retard, 34 % avec un mois de retard, environ 70 % à partir de deux mois.
- **Plus le plafond est bas, plus le risque est élevé** : 32 % de défauts jusqu'à 50 000 TWD, 14 % au-delà de 270 000 TWD.
- Les factures des 6 mois sont très corrélés entre elles (0,80 à 0,95), les retards aussi (0,47 à 0,82) : beaucoup d'information est en double.
- Seulement 22,1 % de défauts : prédire « pas de défaut » pour tout le monde donne déjà 77,9 % d'accuracy. D'où un **découpage stratifié** et des métriques adaptées.

3.3 Audit de fuite et variables construites

En effet chaque variable est connue avant la décision prise, c'est-à-dire entre la déclaration de septembre et le paiement suivant. Cela s'applique au retard, à la facture, au paiement et à la limite. Aucune variable connue seulement après la défaillance (comme le montant récupéré ou la date de la défaillance) n'est utilisée. **Le sexe, l'âge et le statut matrimonial ne sont pas pris en compte** afin d'éviter la discrimination. Le niveau d'éducation a été inclus mais ensuite exclu en partie 4 de l'expérience.

J'ai créé trois variables (src/donnees.py) : **le nombre de mois de retard** sur les 6 derniers mois (la corrélation avec la défaillance est égale à 0.40, la plus élevée), **le taux d'utilisation** (ratio de la facture et de la limite) et **le taux de remboursement** de la facture.

4. Développement du modèle

4.1 Découpage, pipeline et validation

Un sous-ensemble de **20% de la clientèle (6000)** a été réservé comme un ensemble de test et a été échantillonné avec une méthode d'échantillonnage stratifié. L'ensemble de test de 20% est **utilisé une seule fois** à la toute fin. Pour chacun des 24000 clients de l'ensemble d'entrainement le modèle est affiné par **GridSearchCV** avec une **validation croisée stratifiée à 5 plis** et utilise l'AUC-ROC comme critère d'évaluation. Dans la régression logistique la phase de pré-traitement (le logarithme des montants puis la standardisation) est effectuée dans le **Pipeline**. Pour les arbres aucun tel pas de pré-traitement n'est nécessaire. Tous les états aléatoires sont fixés (random_state = 42).

Tableau 3 – Modèles comparés en validation croisée (train, 24 000 clients)

Modèle	Réglage retenu	AUC train	AUC validation (± écart-type)
Baseline (prédit toujours « pas de défaut »)	–	–	0,500
Règle actuelle (retard ≥ 1 mois)	Aucun (calculée sur le train)	–	0,688
Régression logistique	C = 0,003	0,759	0,758 ± 0,006
Arbre de décision	Profondeur 8, feuilles ≥ 400	0,790	0,774 ± 0,004
Random Forest (retenue)	**200 arbres, profondeur 14, feuilles ≥ 50**	**0,835**	**0,786 ± 0,005**

Trois modèles surpassent la Baseline et la règle actuelle. **La Random Forest est le plus performant (0,786)** et l'écart entre eux est plus significatif que leurs écarts types : ils ne viennent pas du processus de division aléatoire. L'inclusion du niveau d'éducation ne change rien non plus (0,786 dans les deux scénarios) :je vais définitivement la supprimer, c'est un trait social en moins à prendre en compte.

4.2 Diagnostic

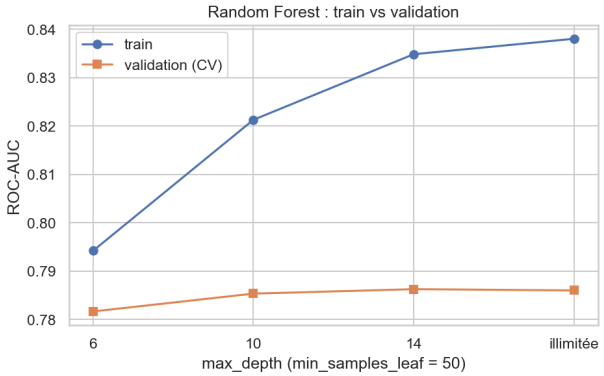


Figure 2 – AUC train et validation selon la profondeur (notebook 02)

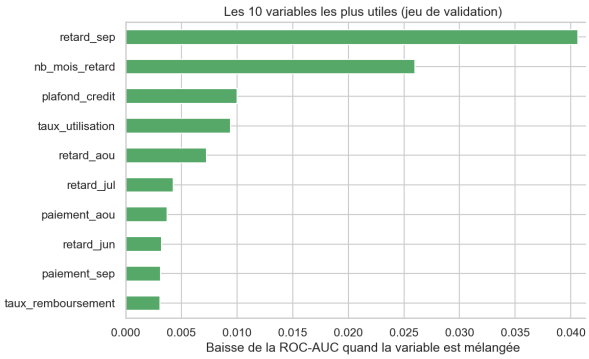


Figure 3 – Importance des variables par permutation (notebook 02)

- **Sur-apprentissage limité** : l'AUC du train monte avec la profondeur (0,79 à 0,84), mais la validation plafonne vers 0,786 dès 10 niveaux. L'écart du modèle retenu (0,835 contre 0,786) reste modéré grâce aux feuilles d'au moins 50 clients.
- **Variables utiles** : le retard de septembre et le nombre de mois en retard dominent, puis le plafond et le taux d'utilisation. Le motif d'appel est donc simple à expliquer au conseiller.
- **Erreurs typiques** : sur une partie de validation, le modèle trouve 583 défauts et en rate 479 ; **78 % des défauts ratés concernent des clients sans aucun retard sur 6 mois**. Leur historique ressemble à celui des bons clients : il faudrait d'autres données (revenus, autres crédits) pour les repérer.

5. Choix des métriques

La décision consiste à **classer les clients du plus au moins risqué**, puis à appeler les premiers dans la limite de la capacité de l'équipe.

- **Métrique principale : ROC-AUC.** Elle mesure si le modèle place les défauts avant les non-défauts, sans choisir de seuil.
- **Métrique métier : rappel à nombre d'appels égal**, puis part des montants en défaut couverts (partie 6).
- **Suivi : PR-AUC**, plus sensible à la classe minoritaire.
- **Garde-fou : la capacité d'appel.** Jamais plus de clients appelés qu'aujourd'hui.
- **Accuracy écartée** : 77,9 % sans trouver un seul défaut.

Je n'ai pas rééquilibré les classes : je veux des **probabilités réalistes**, puisque je les multiplie ensuite par le montant.

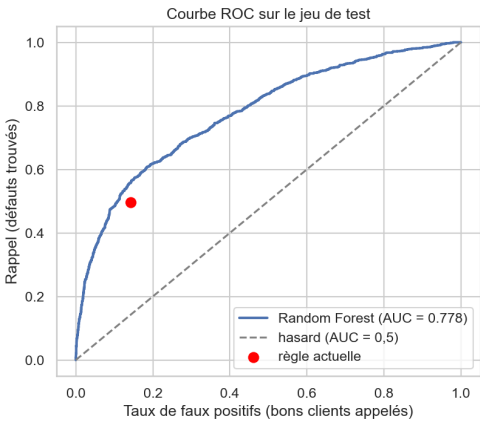


Figure 4 – Courbe ROC sur le jeu de test (notebook 02)

Tableau 4 – Évaluation finale sur le jeu de test (6 000 clients, utilisé une seule fois)

Politique (22,1 % des clients appelés)	ROC-AUC	PR-AUC	Rappel	Précision
Règle actuelle	0,678	0,359	49,7 %	49,8 %
Random Forest, triée par probabilité	**0,778**	**0,557**	**53,9 %**	**54,0 %**

Sur le test, l'AUC (0,778) reste proche de la validation (0,786) : le modèle généralise bien. **Traduction métier : sur 100 défauts, le modèle en anticipe 54, la règle 50**, pour le même nombre d'appels.

6. Justification par les coûts

6.1 Des probabilités fiables

Pour multiplier la probabilité par le montant il est nécessaire que la probabilité soit correcte. Je l'ai vérifié sur les données du train avec des prédictions hors pli en classant les clients en fonction de la probabilité en 10 groupes et en comparant la moyenne de la probabilité prédite avec le taux par défaut. Les points se trouvent presque sur la diagonale et la moyenne de la probabilité prédite (22,1%) est égale au taux par défaut. Ainsi je suis en mesure de calculer une **perte attendue = probabilité de défaut × montant de la facture**.

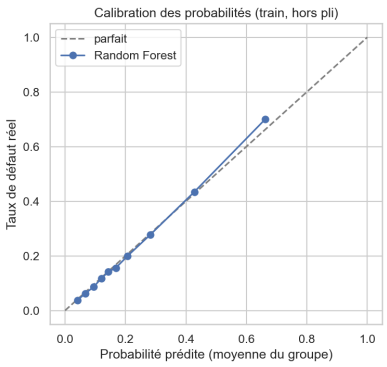


Figure 5 – Calibration des probabilités (notebook 03)

6.2 Hypothèses de coût

Je ne dispose pas des coûts réels de la banque. Mais je fais des **hypothèses prudentes** basées sur des informations publiques (annexe A) et je les mets dans src/couts.py pour une modification facile.

Tableau 5 – Hypothèses de coût

Hypothèse	Valeur	Appui
Taux de change	1 € = 40,0 TWD	Moyennes 2005 de la Réserve fédérale (G.5A)
Montant à risque	Facture de septembre (0 si négative)	Ce que le client doit payer
Perte si le défaut n'est pas anticipé	10 % du montant	61 à 71 % des retards d'un mois sont régularisés (FICO, 2019) ; 10 à 15 % récupérés après passage en perte (Fed de Philadelphie, 2012)
Efficacité d'un appel préventif	Évite 10 % de cette perte	4 à 7 % pour un simple rappel par SMS ou application (Campbell et al., 2022) : valeur prudente pour un appel
Coût d'un appel	10 €	Environ 10 minutes ; 50 à 60 € l'heure de centre d'appels interne (AFRC, 2010)
Passage à l'année	× 5 × 12	Le test représente 1/5 d'un portefeuille de 30 000 clients, décision mensuelle
Coût du projet (1re année)	55 000 €	30 000 € de développement (≈ 56 jours à 533 € par jour, Kicklox 2025), 15 000 € d'intégration, 10 000 € d'exploitation

6.3 Matrice de coûts et seuil de rentabilité

Tableau 6 – Matrice de coûts pour un client de montant M

Décision	Défaut	Pas de défaut
Appelé	10 € + 10 % × M × (1 − 10 %)	10 €
Pas appelé	10 % × M (défaut manqué)	0 €

Un appel coûte 10 € et fait gagner en moyenne probabilité × M × 10 % × 10 %. Il est donc rentable si :

Perte attendue > 10 € / (10 % × 10 %) = 1 000 €

Ce seuil vient des hypothèses, il n'est pas réglé sur le test.

6.4 Comparaison des politiques sur le test

J'ai comparé, sur le mois de test, la règle actuelle, le modèle avec **la même capacité d'appels** (en commençant par les plus fortes pertes attendues) et **trois seuils** de perte attendue.

Tableau 7 – Politiques comparées sur le test (6 000 clients, 1 mois)

Politique	Clients appelés	Défauts trouvés	Appels utiles	Montants couverts	Gain par mois
Règle actuelle	22,1 %	49,7 %	49,8 %	55,3 %	Référence
Modèle, même capacité (retenu)	**22,1 %**	**36,4 %**	**36,5 %**	**80,3 %**	**4 202 €**
Modèle, seuil 500 €	14,6 %	28,0 %	42,4 %	71,5 %	7 195 €
Modèle, seuil 1 000 € (rentabilité)	7,0 %	16,2 %	51,2 %	53,8 %	8 788 €
Modèle, seuil 2 000 €	2,0 %	5,9 %	65,5 %	29,5 %	7 712 €

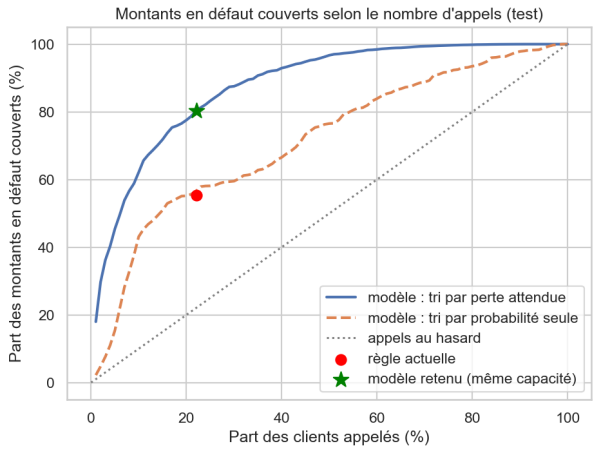


Figure 6 – Montants en défaut couverts selon la part de clients appelés (notebook 03)

Avec la même capacité le modèle identifie **80,3% des montants mauvais contre 55,3%** pour la règle : sur chaque 100€ qui se perdent il identifie 80 tandis que la règle en identifie 55. **Le critère de réussite (au moins 70%) est atteint**. Cependant il identifie moins de défauts (36,4% contre 49,7%) :il laisse les petits montants mauvais pour se concentrer sur les gros. Ceci est fait exprès car le coût des montants mauvais dépend du montant. Trier selon la probabilité ne serait que légèrement plus efficace que la règle (56,5%). Le seuil de 1000€ est le seuil le plus rentable selon mes hypothèses mais il repose fortement sur l'efficacité des appels qui n'est pas mesurée. Ainsi je vais garder la même capacité :il atteint le critère de réussite et ne change pas l'équipe.

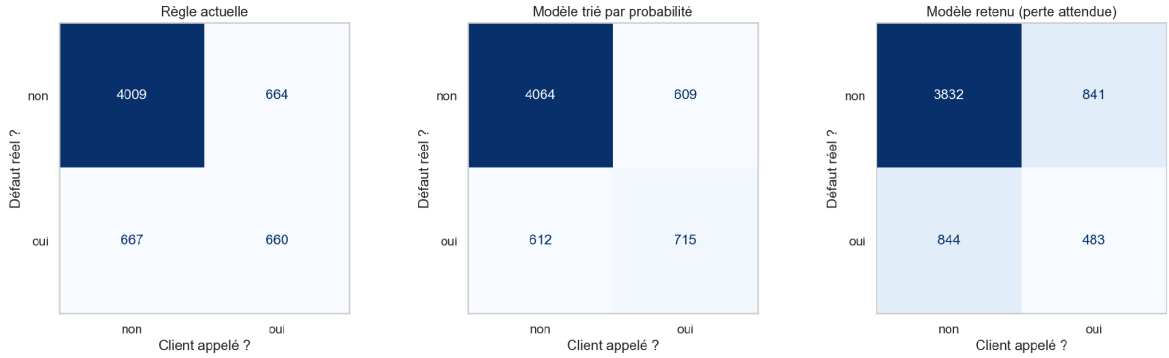


Figure 7 – Matrices de confusion sur le test, à nombre d'appels égal (lignes : réalité, colonnes : décision) (notebook 03)
Règle : 660 défauts trouvés et 664 appels inutiles – modèle retenu : 483 et 841, mais 80,3 % des montants couverts

7. ROI potentiel

Les formules utilisées sont : **gain annuel** = coût avec la règle -coût avec le modèle calculé pour le mois de test puis multiplié par 5x12 ; **ROI** = (gain annuel -coût du projet) /coût du projet ; **Période de remboursement** =coût du projet / (gain annuel /12). Sans changement du nombre d'appels tous les gains sont dus à un meilleur ciblage. Pour le cas central le gain est de 4202€ pour le mois de test soit **252122€**

par an, à partir d'un projet de 55000€ : **ROI de 358%** la première année et remboursement en **2,6 mois**. Le Bootstrap, utilisant 2000 tirages sur les 6000 clients de test, montre un gain dans la fourchette de **197000€ à 309000€** dans 90% des tirages et plus que le coût du projet dans tous les tirages. Je m'expérimente maintenant avec différentes pertes et efficacités mais avec la même politique d'appel.

Tableau 8 – Scénarios de ROI

Scénario	Perte	Efficacité	Gain annuel	ROI 1re année	Retour
Central	10 %	10 %	252 122 €	358 %	2,6 mois
Pessimiste (niveau d'un simple SMS)	**5 %**	**5 %**	**63 030 €**	**15 %**	**10,5 mois**
Optimiste	15 %	20 %	756 365 €	1 275 %	0,9 mois
Gain compté sur 6 mois seulement	10 %	10 %	126 061 €	129 %	–

À retenir : Le projet reste rentable même dans le scénario le plus conservateur. Il est rentable dès que les appels empêchent seulement **2,2% des pertes** alors que même un simple rappel (SMS) permet de prévenir de 4 à 7% des retards selon les études. **L'efficacité d'un appel est l'hypothèse clé** ici c'est-à-dire le chiffre qui doit être mesuré par le pilote.

8. Présentation des résultats

La présentation s'adresse à un décideur non spécialiste, accompagné d'experts techniques (le jury). La structure de la présentation est la suivante : **Problème → Données → Approche → Résultats → Valeur → Limitations** et un seul message par diapositive est indiqué dans le titre. Le paramètre crucial pour le décideur est **la part des sommes couvertes** "sur chaque 100€ qui partent en défaut le modèle couvre 80€ la règle 55€" plutôt que l'AUC ; l'expert doit voir la validation croisée, le test et les matrices de confusion. Tous les chiffres de cette présentation et de ce rapport sont extraits des sorties des notebooks.

9. Risques et enjeux

9.1 Équité

Le sexe, l'âge et le statut matrimonial n'ont pas été utilisés dans ce modèle mais celui-ci peut les détecter indirectement. J'ai donc dû comparer les groupes en utilisant ce test. Dans ce cas être appelé n'est pas une punition mais plutôt une aide afin d'éviter le risque d'une aide moins importante pour un groupe.

Tableau 9 – Contrôle par groupe sur le test (politique retenue)

Groupe	Clients	Appelés	Taux de défaut	Défauts trouvés
Femmes	3 598	21,8 %	21,3 %	37,9 %
Hommes	2 402	22,5 %	23,4 %	34,4 %
21-25 ans	767	20,3 %	25,6 %	34,7 %
26-35 ans	2 492	22,4 %	19,7 %	36,7 %
36-45 ans	1 775	22,6 %	22,4 %	38,5 %
46-55 ans	788	21,4 %	25,1 %	33,8 %
56 ans et plus	178	22,5 %	25,8 %	32,6 %

Ces différences entre les sexes sont assez minimes. Les personnes dans la tranche d'âge de **21-25 ans** ont une chance un peu plus petite d'être appelées (20,3%), mais leur probabilité par défaut est assez élevée **(25,6%)** ; de plus leur facture est légèrement plus basse (facture médiane d'environ 19 500 TWD contre 22 000 à 25 000 TWD pour les 26-45 ans et les 56 ans et plus ; les 46-55 ans sont dans le même cas, avec environ 19 700 TWD) et donc leurs pertes potentielles également. Ceci se produit en conséquence du processus de tri.

9.2 Registre des risques

Tableau 10 – Registre des risques

Risque	Probabilité	Impact	Mesure de réduction
L'appel est moins efficace que prévu	Moyenne	Élevé	Pilote de 3 mois avec groupe témoin ; projet rentable dès 2,2 % d'efficacité.
Dérive : les clients d'aujourd'hui ne ressemblent pas à ceux de Taïwan en 2005 (année de crise)	Élevée	Élevé	Réentraîner sur les données récentes de la banque avant tout déploiement ; suivre chaque mois l'AUC et les montants couverts.
Défauts de clients sans aucun retard passé invisibles	Certaine	Moyen	Limite connue ; ajouter d'autres données (revenus, autres crédits).
Petits montants moins appelés (tri par perte attendue)	Élevée	Moyen	Suivre les taux d'appel par groupe ; réserver si besoin une part des appels aux fortes probabilités.
Sur-apprentissage ou fuite de données	Faible	Élevé	Découpage avant toute préparation, Pipeline, test utilisé une seule fois, écart train / validation surveillé.
Discrimination indirecte	Faible	Élevé	Variables protégées exclues ; contrôle par groupe refait à chaque réentraînement.
Données personnelles (RGPD)	Moyenne	Élevé	Pas d'identité dans le modèle, accès limité aux scores, information des clients ; le conseiller garde la décision.
Les conseillers n'utilisent pas l'outil	Moyenne	Moyen	Même nombre d'appels qu'aujourd'hui et un motif clair pour chaque appel (retards, plafond, montant).
Cible mal définie (mois du défaut non documenté)	Faible	Moyen	Vérifier la définition du défaut avec la banque avant le pilote.

Coût environnemental : faible. Le modèle s'entraîne en quelques minutes sur un ordinateur portable et serait réentraîné au plus une fois par mois.

Conclusion et recommandation

Avec le même nombre d'appels qu'actuellement en ciblant les clients ayant les plus grandes pertes attendues (risque de défaut × montant) on pourrait atteindre **80,3% du montant total des créances en défaut** alors qu'avec la règle actuelle on ne peut atteindre que **55,3%**. L'objectif est atteint et le gain pourrait être calculé à environ **252 000€ par an** pour un projet d'une valeur de 55 000€. La valeur est une estimation basée sur des hypothèses de coûts principalement l'efficacité d'un appel. Les prochaines étapes :

- **Pilote de 3 mois** sur une partie des clients, avec un groupe témoin non appelé, pour mesurer l'efficacité réelle des appels ;
- **Réentraîner le modèle** sur les données récentes de la banque, puis suivre chaque mois l'AUC, les montants couverts et les taux d'appel par groupe ;
- Tester pendant le pilote le **seuil de 1 000 €** de perte attendue, qui pourrait réduire fortement le nombre d'appels ;
- Chercher des **données complémentaires** (revenus, autres crédits) pour repérer les défauts sans retard passé.

Annexe A – Sources des hypothèses

[1] Réserve fédérale (2006). Foreign Exchange Rates, release G.5A, moyennes annuelles 2005. https://www.federalreserve.gov/Releases/g5a/20060103/G5A.htm

[2] FICO (2019). UK card delinquency roll rates creep higher. https://www.fico.com/blogs/uk-card-delinquency-roll-rates-creep-higher

[3] Federal Reserve Bank of Philadelphia (2012). Working Paper 12-18. https://www.philadelphiafed.org/-/media/FRBP/Assets/working-papers/2012/wp12-18.pdf

[4] Campbell, Grant et Thorp (2022). Journal of Banking & Finance, vol. 142. https://ideas.repec.org/a/eee/jbfina/v142y2022ics0378426622001431.html

[5] VoxDev. Behavioural messaging campaigns to reduce loan delinquency (expérience en Colombie). https://www.voxdev.org/topic/finance/how-can-behavioural-messaging-campaigns-be-tailored-reduce-loan-delinquency

[6] Banque des Territoires (2010). Relocalisation des centres d'appels : un effet d'annonce (chiffres de l'AFRC). https://www.banquedesterritoires.fr/relocalisation-des-centres-dappels-un-effet-dannonce

[7] Kicklox / Groupe Didaxis (2025). Étude TJM des freelances tech. https://www.kicklox.com/wp-content/uploads/2025/10/KICKLOX-GROUPE-DIDAXIS-Etude-2025-TJM-freelances-tech_compressed.pdf

[8] Taipei Times (9 mars 2006). Contexte de la crise des cartes de crédit à Taïwan. https://www.taipeitimes.com/News/biz/archives/2006/03/09/2003296519

Contexte : les données datent de 2005, en pleine crise des cartes de crédit à Taïwan. Fin 2005, 12 à 15 % des encours de cartes y passaient en perte chaque année, contre environ 6 % avant la crise (Taipei Times, 2006). C'est une raison de plus pour réentraîner le modèle sur des données récentes.

Annexe B – Données et reproductibilité

- **Données** : Yeh, I. (2009). Default of Credit Card Clients [Dataset]. UCI Machine Learning Repository, id 350, licence CC BY 4.0, https://doi.org/10.24432/C55S3H. Date de consultation : 09/10/2026. Le fichier brut (2,8 Mo) est inclus dans le dépôt.
- **Dépôt Git** : README, requirements.txt, data/, notebooks/ (01_cadrage_eda, 02_modelisation, 03_decision_roi), src/ (donnees.py, couts.py), reports/ (figures, métriques, rapport, slides).
- **Exécution** : Python 3.9 avec les versions de requirements.txt (scikit-learn 1.6.1, pandas 2.3.3, numpy 2.0.2, matplotlib 3.9.4, seaborn 0.13.2). Lancer les notebooks dans l'ordre 01, 02 puis 03 avec « Restart & Run All » : le notebook 02 enregistre le modèle que le notebook 03 utilise.
- **Reproductibilité** : random_state = 42 partout, chemins relatifs, test utilisé une seule fois. Les chiffres de ce rapport sont ceux produits par les notebooks.
- **Dictionnaire des variables** : nom, type, unité et signification de chaque variable (notebook 01, partie 3).