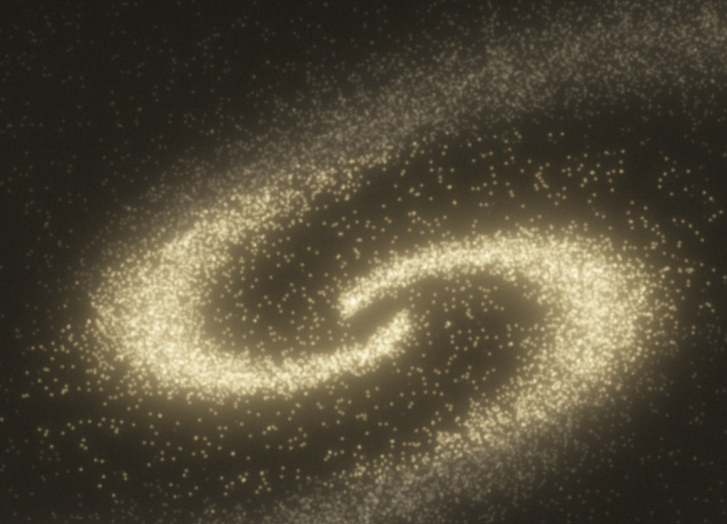
ECAM EPMI
GRADUATE SCHOOL OF ENGINEERING

PROJET FINAL · S7MOI1

SCIENCE DES DONNÉES · RISQUE DE CRÉDIT

QUI APPELER AVANT LE DÉFAUT ?

Mieux cibler les appels préventifs d'une banque grâce à un modèle de risque de défaut sur carte de crédit.



Cheikh Mohamed Vadel Mamina

2AE · ECAM-EPMI · Encadrant : Yann Skonieczny · Octobre 2026

chaque point, un client · 30 000

en or, les 22 % à appeler en priorité

01 — LE PROBLÈME

La règle actuelle ne couvre que 55 % des pertes

23 %

AUJOURD'HUI

des clients appelés chaque mois : ceux déjà en retard sur leur dernière facture

55 %

CE QUE ÇA COUVRE

des montants qui partent en défaut le mois suivant

70 %

MON OBJECTIF

au moins, avec exactement le même nombre d'appels



repère : objectif 70 %

LA DÉCISION À AMÉLIORER Qui appeler ce mois-ci, sans appeler plus de monde qu'aujourd'hui.

Hypothèse : la banque appelle aujourd'hui les clients en retard

Des données réelles, propres et sans fuite



23
variables : plafond, profil, retards, factures, paiements

6 mois
d'historique, d'avril à septembre 2005

6 636
défauts le mois suivant, sur 30 000

QUALITÉ DES DONNÉES

- Aucune valeur manquante, aucun identifiant en double
- Codes non documentés regroupés dans « autre »
- « 1 mois de retard » quasi absent hors septembre : une limite

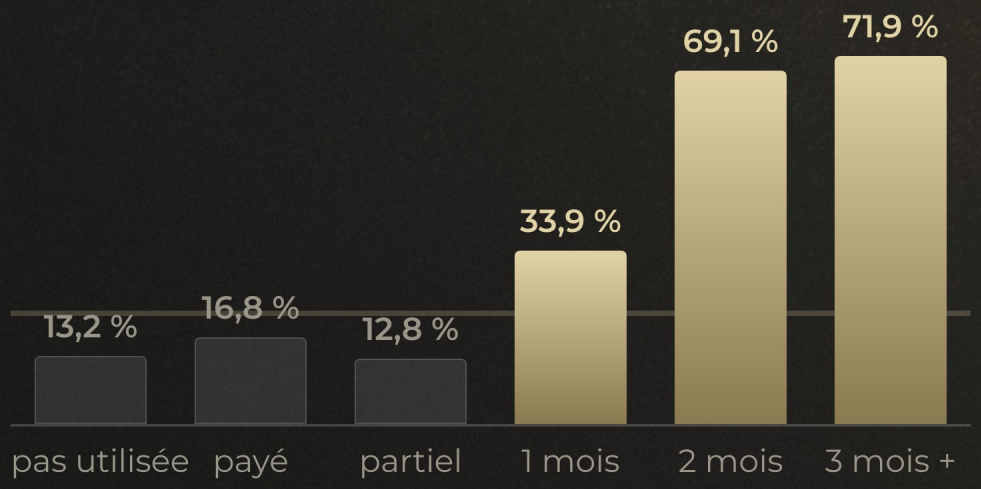
PAS DE FUITE

- Seulement ce qui est connu fin septembre
- Sexe, âge et situation familiale exclus
- Test mis de côté avant toute étape apprise

Yeh (2009), UCI Machine Learning Repository, id 350, CC BY 4.0

Le retard de paiement annonce le défaut

DÉFAUT SELON LE RETARD DE SEPTEMBRE



DÉFAUT SELON LE PLAFOND (TWD)



Sans retard, 13 à 17 % de défauts. **Deux mois de retard : 69 %.** Les petits plafonds font aussi plus défaut.

Notebook 01 · ligne : taux moyen de 22 % · en or : au-dessus

Un pipeline sans fuite, de bout en bout

01 **Données**

30 000 clients, 22 variables retenues

02 **Découpage**

80 % train, 20 % test, stratifié

03 **Préparation**

log et mise à l'échelle dans un Pipeline

04 **3 modèles**

GridSearchCV, validation croisée à 5 plis

05 **Test**

utilisé une seule fois, sur le modèle final

06 **Décision**

probabilité × montant : qui appeler

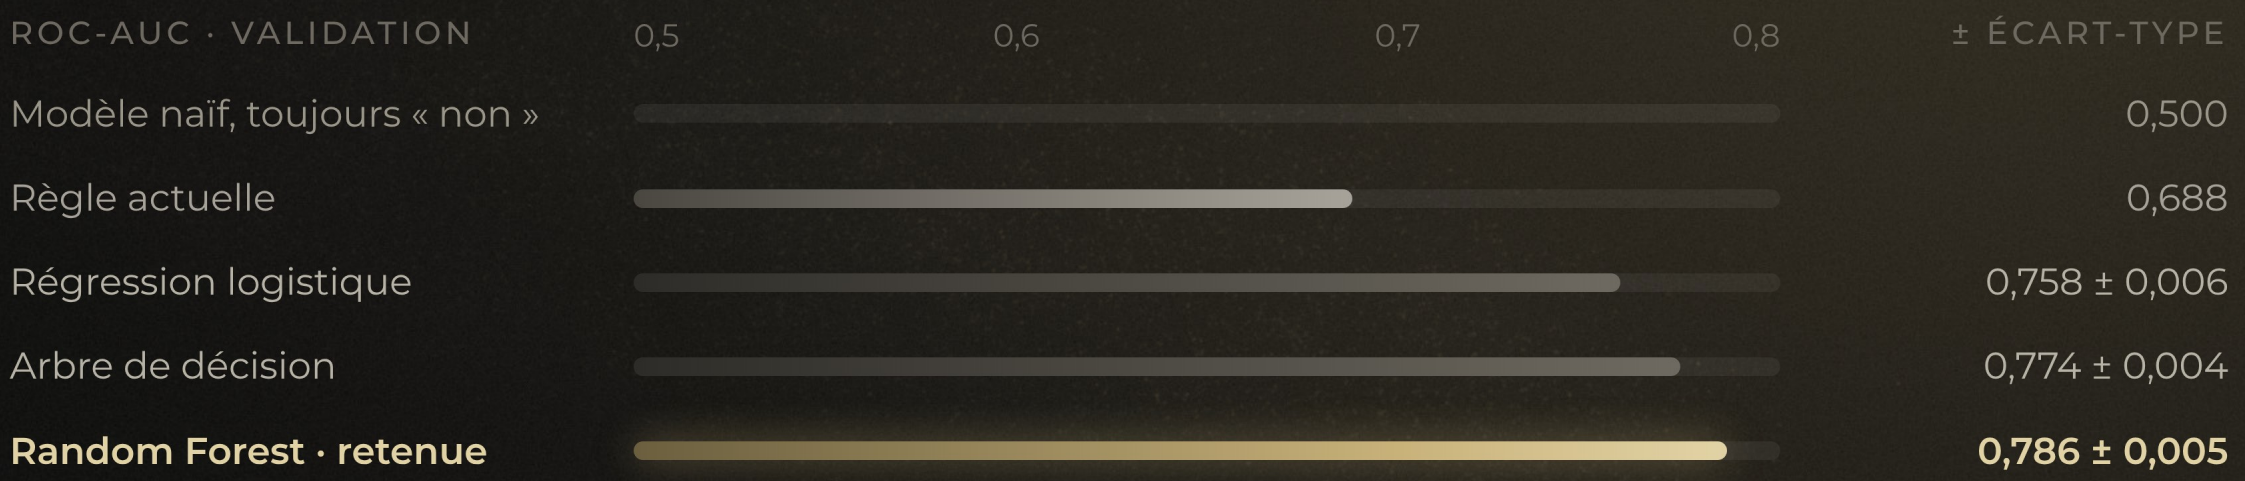
TYPE DE PROBLÈME

La cible est connue : défaut, oui ou non. C'est une classification binaire supervisée, et le modèle donne une probabilité.

ALTERNATIVES ÉCARTÉES

Régression : la perte réelle est inconnue. Clustering : ignorerait la cible. Série temporelle : une seule date.

La Random Forest arrive en tête



SUR-APPRENTISSAGE

0,835 en train, 0,786 en validation : écart limité

RÉGLAGE RETENU

200 arbres, profondeur 14, au moins 50 clients par feuille

VALIDATION

croisée à 5 plis, sur le train seul : 24 000 clients

Notebook 02 · GridSearchCV, moyenne sur 5 plis

Sur le test, le modèle bat la règle

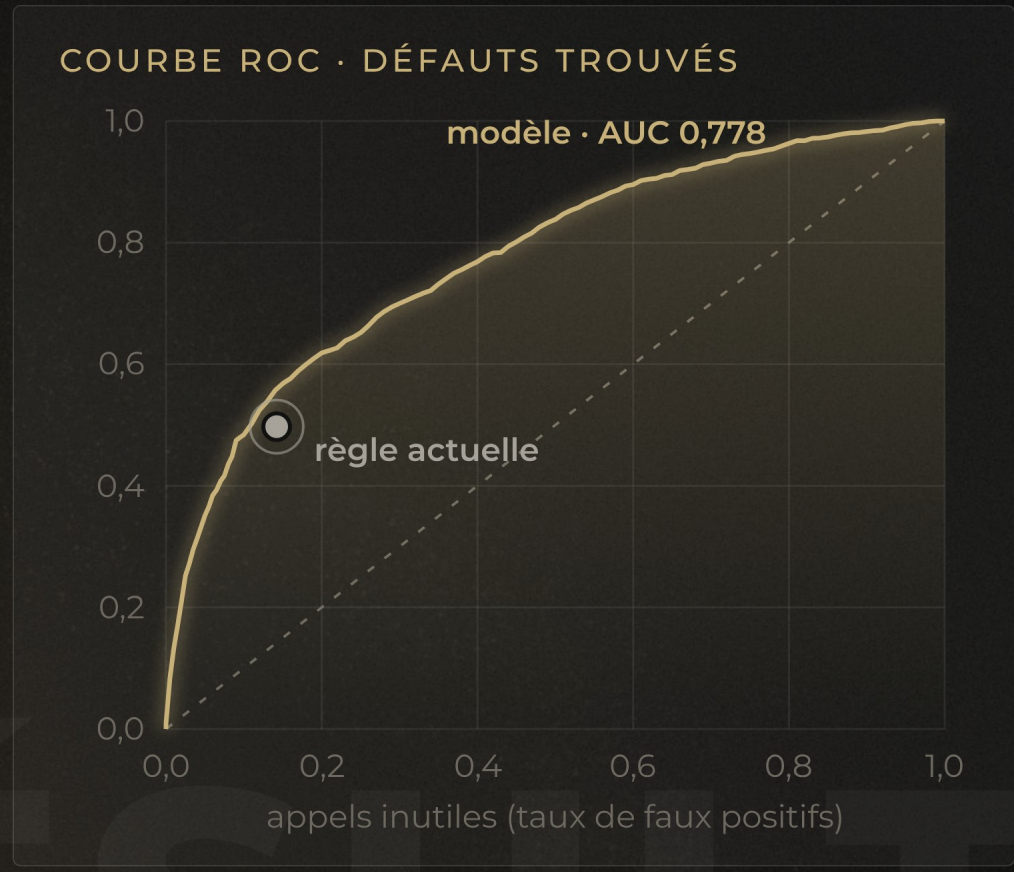
ROC-AUC SUR LE TEST

0,778 règle : 0,678

DÉFAUTS ANTICIPÉS, À APPELS ÉGAUX

54 / 100 règle : 50

Presque rien de perdu par rapport à la validation (0,786) : le modèle généralise bien. Le test n'a servi qu'une fois.



Ce qui compte, c'est l'argent perdu



COÛT D'UN CLIENT DONT LA FACTURE VAUT M

	défaut	pas de défaut
Appelé	10 € + 10 % × M × 0,9	10 € · appel inutile
Pas appelé	10 % × M · défaut manqué	0 €

Hypothèses : un défaut manqué coûte 10 % de M, un appel en évite 10 %, un appel coûte 10 €.

SEUIL DE RENTABILITÉ

1 000 €

Un appel est rentable dès que la perte attendue dépasse 10 € ÷ (10 % × 10 %).

Je garde le même nombre d'appels



Règle actuelle — référence

22,1 % appelés · 55,3 % couverts

Seuil 1 000 € — rentable, mais fragile

7,0 % appelés · 53,8 % couverts · +8 788 € par mois

Même capacité — retenu · objectif atteint

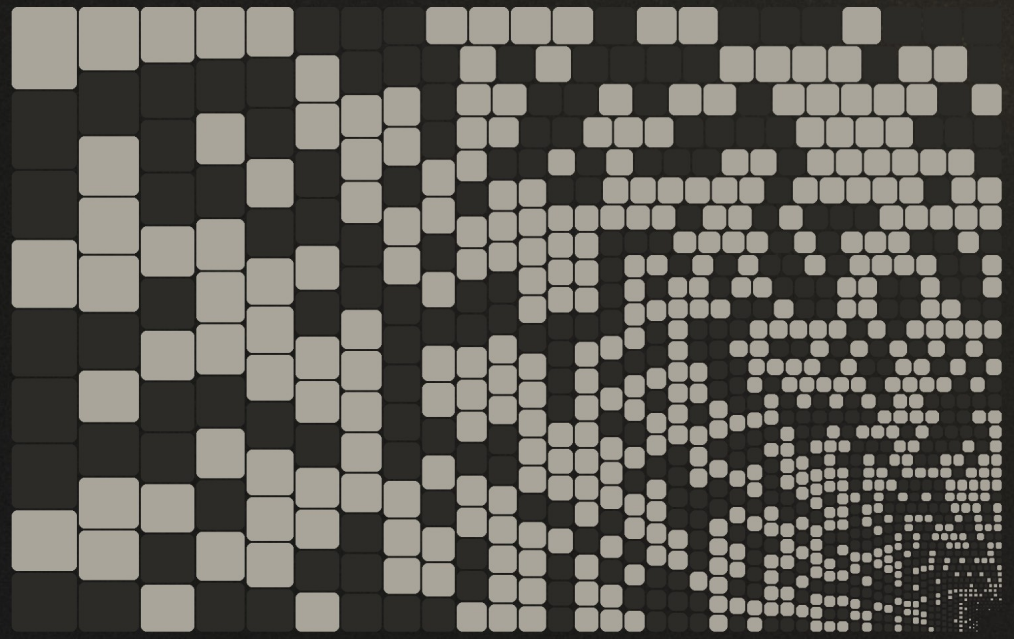
22,1 % appelés · 80,3 % couverts · +4 202 € par mois

Même nombre d’appels, 80 % au lieu de 55 %

RÈGLE ACTUELLE

appelle les clients en retard

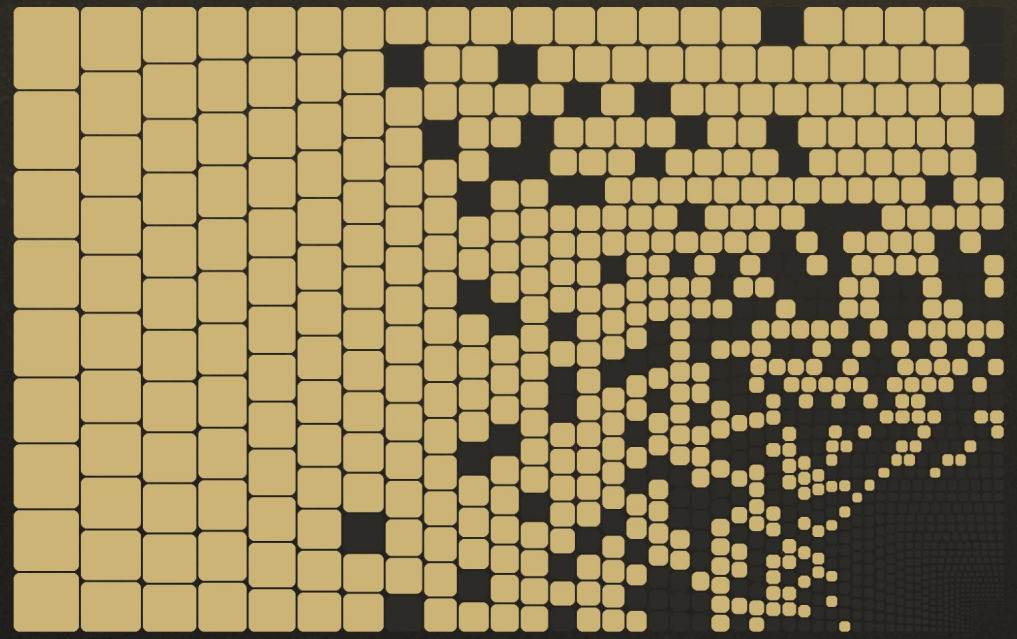
55 %



MODÈLE RETENU

appelle les plus fortes pertes attendues

80 %



1 carré = 1 client en défaut, taille = sa facture · en couleur : les clients appelés

Moins de défauts trouvés, mais les plus gros

DÉCISION RETENUE · 6 000 CLIENTS DU TEST

	appelé	pas appelé
Défaut	483 défauts anticipés	844 défauts manqués
Sans défaut	841 appels inutiles	3 832 bons clients

indicateur	RÈGLE	PROBA	RETENU
Défauts trouvés	49,7 %	53,9 %	36,4 %
Précision	49,8 %	54,0 %	36,5 %
Montants couverts	55,3 %	56,5 %	80,3 %

78 % des défauts ratés en validation concernent des clients **sans aucun retard sur 6 mois**. Leur historique ressemble à celui des bons clients : il faudrait d'autres données, comme les revenus ou les autres crédits.

Notebooks 02 et 03 · 22,1 % des clients appelés dans les trois cas

Environ 250 000 € gagnés par an

252 122 €

de gain par an · entre 197 000 et 309 000 € dans 90 % des tirages

358 %

de ROI la première année, pour un projet de 55 000 €

2,6 mois

pour rembourser le projet



RENTABLE DÈS

2,2 %

des pertes évitées par les appels. Un simple SMS réduit déjà les retards de 4 à 7 %.

Notebook 03 · gain du mois de test × 5 × 12 · bootstrap, 2 000 tirages

Avant de déployer, cinq points à vérifier

01

L’efficacité des appels

Elle n’est pas mesurée : c’est l’hypothèse clé. Le projet reste rentable dès 2,2 %.

02

Des données anciennes

Taïwan, 2005, une année de crise. Il faut réentraîner sur les données de la banque et suivre l’AUC chaque mois.

03

Des défauts invisibles

Les clients sans retard passé échappent au modèle. Il faudrait les revenus ou les autres crédits.

04

L’équité entre groupes

Les 21-25 ans sont un peu moins appelés : 20,3 % contre 22,1 %. À suivre à chaque réentraînement.

05

Les données personnelles

RGPD : pas d’identité dans le modèle, accès limité aux scores, et le conseiller garde la décision.

MA RECOMMANDATION

Un pilote de 3 mois

Sur une partie des clients, avec un groupe témoin tiré au hasard, pour mesurer l’efficacité réelle des appels.

- Coût environnemental faible : quelques minutes d’entraînement sur un ordinateur portable, au plus une fois par mois.

MERCI

POUR VOTRE ATTENTION



80 % des montants en défaut couverts, contre 55 %, avec les mêmes appels

250 k€ de gain estimé par an, pour un projet de 55 000 €

3 mois de pilote avec un groupe témoin, pour le vérifier

Cheikh Mohamed Vadel Mamina

Code, notebooks et rapport dans le dépôt Git du projet

PLACE À VOS QUESTIONS